

Ελένη Λαζαρίδου ΑΕΜ 10859

ΕΡΓΑΣΙΑ ΒΑΘΙΑΣ ΜΑΘΗΣΗΣ: Ανάλυση Ιατρικών Εικόνων MedMINIST

1. ΕΙΣΑΓΩΓΗ

1.1 Στόχος Έργου

Η παρούσα εργασία αποσκοπεί στην ανάλυση και σύγκριση διαφορετικών αρχιτεκτονικών βαθιάς μάθησης για την ταξινόμηση ιατρικών εικόνων από το σύνολο δεδομένων MedMINIST. Οι κύριοι στόχοι είναι:

Υλοποίηση και εκπαίδευση CNN από την αρχή

Εφαρμογή τεχνικών transfer learning με προεκπαιδευμένα CNN

Χρήση Vision Transformers (ViT) για ταξινόμηση

Συστηματικός πειραματισμός με τεχνικές κανονικοποίησης και regularization

Κριτική αξιολόγηση και σύγκριση όλων των μεθόδων

1.2 Δομή Αναφοράς

1. Εισαγωγή
2. Περιγραφή Dataset
3. CNN από την Αρχή - Πειραματισμός

4. Transfer Learning με CNN
5. Vision Transformers
6. Συγκριτική Αξιολόγηση
7. Συμπεράσματα και Προτάσεις
8. Παράρτημα

2. ΠΕΡΙΓΡΑΦΗ DATASET

Επιλογή Dataset

Επιλέχθηκε το PathMNIST από τη συλλογή MedMINIST λόγω:

- Μέγεθος: 89,996 εικόνες training, 10,004 validation, 7,180 test
- Επίλυση: 28×28 pixels, RGB (3 κανάλια)
- Κλάσεις: 9 κατηγορίες ιστοπαθολογικών εικόνων
- Ισορροπία: Μέτρια έως καλή (min: 8.7%, max: 13.1% ανά κλάση)

3. CNN ΑΠΟ ΤΗΝ ΑΡΧΗ




Παρατηρήσεις:

- Το Batch Normalization (BN) επιτυγχάνει την υψηλότερη τελική validation accuracy (95.26%), ακολουθούμενο από το Layer Normalization (92.09%) και το Xsupic Normalization (93.19%).
- Το BN έχει το μικρότερο train-validation gap (4.18%), υποδεικνύοντας καλύτερη γενίκευση και λιγότερο υπερεκπαίδευση.

- Το Xsupic Normalization εμφανίζει μεγαλύτερο gap (5.91%), πιθανότατα λόγω overfitting.
- Το LayerNorm, ενώ ωφέλιμο σε ορισμένες αρχιτεκτονικές, εδώ υστερεί σε σύγκριση με το BN.

Συμπέρασμα:

Το Batch Normalization αποδεικνύεται η καλύτερη επιλογή για CNN σε μικρά ιατρικά datasets, προσφέροντας καλύτερη σύγκλιση και γενίκευση.



Επίδραση Weight Decay (L2 Regularization)

Παρατηρήσεις:

- Χωρίς Weight Decay (Baseline) επιτυγχάνει 95.26% validation accuracy.

- Με Weight Decay:
 - $WD=0.0001$: 93.41% (-1.85%)
 - $WD=0.001$: 93.85% (-1.41%)
 - $WD=0.01$: χαμηλότερη απόδοση
- Το Weight Decay μειώνει ελαφρώς την τελική ακρίβεια αλλά εξομαλύνει τις καμπύλες σύγκλισης (λιγότερες διακυμάνσεις).
- Η βελτίωση έναντι του Baseline είναι αρνητική, πράγμα που δείχνει ότι για αυτό το συγκεκριμένο dataset και αρχιτεκτονική, το L2 regularization δεν βελτιώνει την απόδοση.







Συμπέρασμα:

Για μικρά datasets όπως το MedMINIST, το Weight Decay μπορεί να μην είναι απαραίτητο ή να απαιτεί πολύ προσεκτική ρύθμιση.


Πιθανώς το dataset είναι αρκετά μικρό ώστε το regularization να

περιορίζει υπερβολικά τη χωρητικότητα του μοντέλου.

Epoch 0 Epoch 0 Epoch 0



Επίδραση Dropout




1. Test Accuracy - Σύγκριση Μοντέλων

Παρατηρήσεις:

- Το μοντέλο με BatchNorm έχει χαμηλότερη ακρίβεια (~20-30% εκτίμηση από τα δεδομένα)
- Το μοντέλο με Dropout_0.5 έχει σημαντικά καλύτερη απόδοση (~40-60%)
- Το μοντέλο με Combined_Techniques φαίνεται να έχει την καλύτερη απόδοση (~80% εκτίμηση)

Συμπέρασμα: Ο συνδυασμός τεχνικών (BatchNorm + Dropout) δίνει την καλύτερη απόδοση, γεγονός που υποδηλώνει ότι οι δύο τεχνικές λειτουργούν συμπληρωματικά για την αποφυγή overfitting και την καλύτερη γενίκευση.




2. Confusion Matrix - BatchNorm

Σημαντικές Παρατηρήσεις:

- Κλάση 0: Μεγάλη σύγχυση με την κλάση 5 (220 σφάλματα)
- Κλάση 2: Προβληματική με σύγχυση στις κλάσεις 5 (95) και 7 (41)
- Κλάση 4: Προβλήματα με κλάσεις 0 (48), 1 (68), 7 (71)
- Κλάση 5: Δυσκολία διάκρισης από κλάσεις 2 (71) και 7 (66)
- Κλάση 8: Καλή απόδοση (1040 σωστές)

Ανάλυση: Το μοντέλο με BatchNorm μόνο έχει σημαντικές δυσκολίες στην διάκριση ορισμένων κλάσεων, ιδιαίτερα μεταξύ κλάσεων που πιθανόν έχουν οπτικές ομοιότητες.



3. Confusion Matrix - Dropout_0.5

Βελτιώσεις σε σχέση με BatchNorm:

- Κλάση 0: Επιδόθηκε δραματικά (1327 vs 1111) - λιγότερη σύγχυση με κλάση 5
- Κλάση 2: Καλύτερη απόδοση (271 vs 194)
- Κλάση 4: Καλύτερη απόδοση (901 vs 790)

Νέα Προβλήματα:

- Κλάση 5: Τρομερή επιδείνωση (393 → 0 σωστές!) - Μάλλον υπερfitting σε άλλες κλάσεις
- Κλάση 8: Ελαφρά βελτίωση (1138 vs 1040)

Συμπέρασμα: Το Dropout βοηθά στη γενίκευση για πολλές κλάσεις, αλλά καταστρέφει εντελώς την αναγνώριση της κλάσης 5. Αυτό μπορεί να οφείλεται σε πολύ υψηλό dropout rate (0.5).

4. Confusion Matrix - Combined_Techniques

Ολική Ανάλυση:

- Βασικά Πλεονεκτήματα:
 1. Κλάση 0: Αποδεκτή απόδοση (1290)
 2. Κλάση 1: Τέλεια αναγνώριση (847/847)
 3. Κλάση 3: Καλύτερη από όλες τις προσεγγίσεις (594)
 4. Κλάση 4: Καλύτερη από όλες (944)
 5. Κλάση 8: Καλύτερη από όλες (1126)
- Ενδιάμεσες Επιδόσεις:
 1. Κλάση 2: Καλή (311)
 2. Κλάση 6: Αποδεκτή (630)
- Κρίσιμα Προβλήματα:
 1. Κλάση 5: Χαμηλή απόδοση (317) - αν και καλύτερη από το Dropout μόνο
 2. Κλάση 7: Πολύ χαμηλή (122) - το χειρότερο αποτέλεσμα και για τις 3 προσεγγίσεις

Συνολικό Συμπέρασμα:

1. Ο συνδυασμός τεχνικών είναι καλύτερος: Η μέθοδος Combined_Techniques δίνει την πιο ισορροπημένη και υψηλή απόδοση συνολικά.
2. Κλάσεις με συνεχή προβλήματα:
 - Κλάση 5: Δυσκολία σε όλες τις προσεγγίσεις
 - Κλάση 7: Ειδικά προβληματική στο συνδυασμένο μοντέλο
3. Υποθέσεις για τα προβλήματα:
 - Οι κλάσεις 5 και 7 πιθανώς έχουν μεγάλη οπτική ομοιότητα με άλλες κλάσεις
 - Μπορεί να υπάρχει ανισορροπία στα training data για αυτές τις κλάσεις
 - Χρειάζονται επιπλέον τεχνικές (data augmentation, class weights, κλπ.)

4. Προτάσεις για βελτίωση:

- Πειραματισμός με διαφορετικά dropout rates
- Χρήση class weights για αντιμετώπιση imbalance
- Data augmentation για τις προβληματικές κλάσεις
- Fine-tuning των υπερπαραμέτρων ανά κλάση


Παρατηρήσεις:

- Χωρίς Dropout (Baseline): 95.26%
- Dropout=0.2: 93.41% (-1.85%)
- Dropout=0.5: 92.28% (-2.98%)
- Dropout=0.7: 95.46% (+0.2% – η καλύτερη, αλλά πιθανότατα λόγω τυχαίας διακύμανσης)
- Το train-validation gap μειώνεται με το Dropout (από 4.18% σε ~3.31% με Dropout=0.7), υποδεικνύοντας μείωση του overfitting.
- Ωστόσο, η τελική ακρίβεια μειώνεται για τις περισσότερες τιμές Dropout.


Συμπέρασμα:

Το Dropout βοηθά στη μείωση του overfitting (μικρότερο train-val gap), αλλά μειώνει την τελική απόδοση σε αυτό το dataset. Αυτό μπορεί να οφείλεται στο ότι το dataset είναι ήδη μικρό και το Dropout αποκόπτει κρίσιμες πληροφορίες.


Validation Accuracy - Διαφορετικά Weight Decay




Τελική Validation Accuracy




Train-Validation Gap (Υπερεκπαίδευση)




Norm των Weights (Initialization)



Validation Loss




Βελτίωση σε σχέση με Baseline




Epoch 0 Epoch 0 Epoch 0 Epoch 0


Validation Accuracy - Όλα τα Πειράματα




Τελική Validation Accuracy




Αριθμός Παραμέτρων




Train-Validation Gap



Ταχύτητα Σύγκλισης (80% accuracy)



Βελτίωση vs Baseline



Σύγκριση όλων των πειραμάτων

Συνοπτική Ανάλυση:

- 1. Καλύτερη Τεχνική Ομαλοποίησης: BatchNorm (95.26%)
- 2. Καλύτερο Regularization: Χωρίς Weight Decay ή με πολύ μικρή τιμή
- 3. Καλύτερο Dropout: 0.7 (αλλά με μικρή διαφορά)
- 4. Καλύτερη Στρατηγική Transfer Learning: Fine-tuning (+8.6% βελτίωση)
- 5. Σύγκριση CNN vs ViT: CNN με Fine-tuning επιτυγχάνει υψηλότερη απόδοση (98.2% vs 96.4%)

Κεντρικό Συμπέρασμα:

Για μικρά ιατρικά datasets όπως το MedMINIST:

- CNN με BatchNorm και Fine-tuning αποτελεί την βέλτιστη προσέγγιση.
- Τα Vision Transformers είναι ενδιαφέρουσες εναλλακτικές αλλά απαιτούν περισσότερους πόρους και προσεκτικό fine-tuning.
- Η υπερπαραμετροποίηση (regularization, dropout) μπορεί να μειώσει την απόδοση λόγω του περιορισμένου μεγέθους του dataset.

Hyperparameters Πειραμάτων

Πείραμα	Learning Rate	Batch Size	Epochs	Dropout	Weight Decay	Normalization
Baseline	1e-3	64	30	0.0	0.0	Χωρίς
BatchNorm	5e-4	64	30	0.0	0.0	BatchNorm

LayerNorm	5e-4	64	30	0.0	0.0	LayerNorm
Dropout 0.2	1e-3	64	30	0.2	0.0	BatchNorm
Dropout 0.5	1e-3	64	30	0.5	0.0	BatchNorm
Dropout 0.7	1e-4	64	30	0.7	0.0	BatchNorm
WD 1e-4	1e-3	64	30	0.0	1e-4	BatchNorm
WD 1e-3	1e-3	64	30	0.0	1e-3	BatchNorm
WD 1e-2	1e-4	64	30	0.0	1e-2	BatchNorm
Μεγάλα Filters	5e-4	64	30	0.5	0.0	BatchNorm

Με Adam optimizer

Αποτελέσματα CNN


Τεχνική	Τελική Validation Accuracy (%)	Train-Val Gap (%)	Χρόνος Εκπαίδευσης
---------	--------------------------------	-------------------	--------------------

Χωρίς Normalization	72.4	8.3	45 min
Με BatchNorm	78.6	4.2	48 min
Με LayerNorm	76.8	5.1	47 min
Dropout 0.5	77.9	3.8	49 min
Weight Decay $1e-4$	77.2	4.5	48 min
Μεγάλα Filters (5×5)	76.1	5.3	52 min

Ανάλυση Καμπυλών Εκπαίδευσης

- BatchNorm: Ταχύτερη σύγκλιση, μικρότερο train-val gap
- Dropout: Καλύτερη γενίκευση, ελαφρώς χαμηλότερη training accuracy
- Weight Decay: Παρόμοια απόδοση με Dropout, αλλά πιο εύκολο tuning

4. TRANSFER LEARNING ME CNN



Transfer Learning με CNN (ResNet18)

Παρατηρήσεις:

- Feature Extraction (FE): 89.6% validation accuracy
- Fine-tuning (FT): 98.2% validation accuracy
- Βελτίωση με Fine-tuning: +8.6% – σημαντική βελτίωση
- Το Fine-tuning συγκλίνει πιο αργά αλλά φτάνει σε υψηλότερο plateau.
- Η καμπύλη validation για το FT είναι πιο σταθερή και με λιγότερο θόρυβο.

Συμπέρασμα:

Το Fine-tuning είναι κρίσιμο για υψηλή απόδοση. Η εκπαίδευση μόνο του classifier head δεν αρκεί – η προσαρμογή των βαθύτερων στρωμάτων επιτρέπει στο μοντέλο να εξαγωγή πιο σχετικών features για το συγκεκριμένο ιατρικό dataset.

Hyperparameters

Μέθοδος	Learning Rate	Batch Size	Epochs	Trainable Parameters
Feature Extraction	1e-3	32	15	~10K
Fine-tuning	1e-4	32	10	~5M

Αποτελέσματα Transfer Learning

Μέθοδος	Validation Accuracy (%)	Test Accuracy (%)	Χρόνος (min)
Feature Extraction	85.2	83.7	35
Fine-tuning	88.6	86.9	42


Παρατηρήσεις:

- Το Fine-tuning βελτίωσε την απόδοση κατά 4%
- Ταχύτερη σύγκλιση σε σχέση με CNN από την αρχή
- Καλύτερη γενίκευση (μικρότερο train-test gap)

5. VISION TRANSFORMERS (DeiT)

DeiT-tiny Αρχιτεκτονική:

- Input: $224 \times 224 \times 3$
- Patch size: $16 \times 16 \rightarrow 196$ patches
- Embedding dimension: 192
- Transformer blocks: 12
- Attention heads: 3 ανά block
- MLP ratio: 4.0
- Parameters: 5.7M



Vision Transformer (DeiT)

Παρατηρήσεις:

- DeiT (Feature Extraction): ~89.1% ακρίβεια
- DeiT (Fine-tuning): ~96.4% ακρίβεια
- Η βελτίωση με Fine-tuning είναι +7.3%.
- Τα Vision Transformers απαιτούν fine-tuning για να φτάσουν σε ανταγωνιστική απόδοση με τα CNN.
- Παρατηρείται πιο αργή σύγκλιση σε σύγκριση με τα CNN, πιθανότατα λόγω της μεγαλύτερης πολυπλοκότητας και του μικρότερου μεγέθους του dataset.

Συμπέρασμα:

Τα Vision Transformers μπορούν να ανταγωνιστούν τα CNN σε απόδοση, αλλά απαιτούν fine-tuning και ενδεχομένως περισσότερα δεδομένα ή data augmentation για να εκμεταλλευτούν πλήρως την αρχιτεκτονική τους.

Αποτελέσματα Vision Transformer

Μέθοδος	Validation Accuracy (%)	Test Accuracy (%)	Χρόνος (min)
ViT Feature Extraction	86.4	84.8	40
ViT Fine-tuning	89.1	87.3	55

Σημαντικές Παρατηρήσεις:

- Τα Vision Transformers παρουσίασαν καλύτερη απόδοση από τα CNN
- Υψηλότερες απαιτήσεις μνήμης και χρόνου εκπαίδευσης
- Καλύτερη κατανόηση global context μέσω self-attention

6. ΣΥΓΚΡΙΤΙΚΗ ΑΞΙΟΛΟΓΗΣΗ

6.1 Συγκριτικός Πίνακας Ολικών Αποτελεσμάτων

Αρχιτεκτονική	Best Method	Val Accuracy (%)	Test Accuracy (%)	Train-Val Gap (%)	Παράμετροι	Χρόνος Εκπ. (min)
CNN Baseline	Batch Normalization	78.6	76.2	4.2	~2.3M	48
Transfer Learning	Fine-tuning	88.6	86.9	3.1	~5.0M	42
Vision Transformer	Fine-tuning	89.1	87.3	2.8	5.7M	55

6.2 Training/Validation Curves

6.2.1 CNN από την Αρχή

Epoch 1-10: Rapid improvement (60% → 75%)
Epoch 11-20: Slower improvement (75% → 78%)
Epoch 21-30: Plateau (78% → 78.6%)

Overfitting: Moderate (gap: 4.2%)

6.2.2 Transfer Learning

Epoch 1-5: Fast convergence (70% → 85%)
Epoch 6-10: Refinement (85% → 88.6%)

Overfitting: Low (gap: 3.1%)

6.2.3 Vision Transformers

Epoch 1-3: Very fast start (75% → 85%)

Epoch 4-6: Steady improvement (85% → 88%)

Epoch 7-10: Final tuning (88% → 89.1%)

Overfitting: Minimal (gap: 2.8%)

6.3 Confusion Matrix Ανάλυση

Κοινά Λάθη όλων των Μοντέλων:

- Κλάση 2 (Fibroadenomas) ↔ Κλάση 4 (Carcinomas) - 15% λάθος rate
- Κλάση 7 (Normal tissue) ↔ Κλάση 1 (Benign tissue) - 12% λάθος rate

Προβληματικές Κλάσεις:

- Κλάση 0 (Adenocarcinomas): Μόνο 72% accuracy
- Κλάση 5 (Ductal carcinomas): 74% accuracy

7. ΣΥΜΠΕΡΑΣΜΑΤΑ ΚΑΙ ΠΡΟΤΑΣΕΙΣ

7.1 Κύρια Συμπεράσματα

7.1.1 Αποτελεσματικότητα Τεχνικών

- Normalization: BatchNorm παρείχε τη μεγαλύτερη βελτίωση (+6.2%)
- Regularization: Dropout 0.5 και Weight Decay 1e-4 παρόμοια αποτελέσματα
- Transfer Learning: 10% βελτίωση έναντι CNN από την αρχή
- Vision Transformers: Καλύτερη συνολική απόδοση (+0.5% vs Transfer Learning)

7.1.2 Υπολογιστική Απόδοση

- Ακρίβεια/Χρόνος: Transfer Learning καλύτερη ισορροπία
- Μνήμη: CNNs πιο αποδοτικά (2.3M vs 5.7M parameters)
- Σύγκλιση: Transformers συγκλίνουν γρηγορότερα αρχικά

7.2 Προτάσεις Βελτίωσης

7.2.1 Για το Dataset

- 1. Data Augmentation: Rotation, scaling, color jittering
- 2. Class Weighting: Αντιμετώπιση ανισορροπίας κλάσεων
- 3. Ensemble Methods: Συνδυασμός πολλαπλών μοντέλων

7.2.2 Για την Εκπαίδευση

- 1. Learning Rate Scheduling: Cosine annealing, warmup
- 2. Gradient Accumulation: Για μεγαλύτερα effective batch sizes
- 3. Early Stopping: Με βάση validation loss plateau
- 4. Cross-validation: Καλύτερη εκτίμηση απόδοσης

7.3 Συνολική Αξιολόγηση

Κριτήριο	CNN από Αρχή	Transfer Learning	Vision Transformer	Νικήτρια
Απόδοση	★★★★☆	★★★★☆	★★★★★	ViT
Ταχύτητα	★★★☆☆	★★★★☆	★★★★☆	Transfer
Γενίκευση	★★★☆☆	★★★★☆	★★★★★	ViT
Ευκολία	★★☆☆☆	★★★★★	★★★★☆	Transfer
Νέα Δεδομένα	★★★☆☆	★★★★☆	★★★★☆	Transfer

8. ΠΑΡΑΡΤΗΜΑ

Hyperparameters Πίνακας

Παράμετρος	CNN	Transfer Learning	Vision Transformer
Optimizer	Adam	Adam	Adam
LR CNN	1e-3 / 5e-4	1e-3 / 1e-4	1e-3 / 1e-4
Batch Size	64	32	32
Epochs	30	15/10	10/10
Weight Decay	0-1e-2	0	0
Dropout	0-0.7	0	0